1. 物理采集与标签生成 (Data Collection & Labeling)

- **前提条件**：固定 eBPF/perf 的时间窗口（例如 $T = 10$ 秒），并在采集前获取底层 PMU 的 Multiplexing 轮转周期 M。
- **输入变量**：同一种算法的两个编译/重排版本 $v1$ 和 $v2$（输入数据规模严格一致）。
- **操作机制**：
  - 在固定窗口内循环执行 $v1$ 和 $v2$，记录实际执行次数 N_{v1} 和 N_{v2}。
  - 外部裁判逻辑：若 $N_{v1} > N_{v2}$，则生成硬标签 $t = 1$；反之 $t = 0$。
  - 并发采集前端硬件事件（`L1-icache-load-misses`, `iTLB-load-misses`, `branch-misses`, `instructions` 等）与 LBR 物理跳转轨迹。

2. 异构特征对齐与张量构造 (Feature Engineering)

- **前提条件**：隔离宏观执行时间的影响，使特征矩阵仅反映微观架构阻力。
- **变量映射**：
  - **PMU 标度统一**：计算各事件的 MPKI（$C/I \times 1000$），消除总指令数 I 漂移的风险。
  - **LBR 极值压缩**：提取 LBR 栈的统计标量（如平均跳转跨度 X_{lbr_span}），执行非线性压缩 $X'_{lbr} = \log(1 + X_{lbr_span})$。
- **输出结构**：拼接生成双塔网络的独立输入张量 $X_{v1}, X_{v2} \in \mathbb{R}^{T \times D}$（其中 T 为时间步序列长度，D 为对齐后的混合特征维度）。

3. Siamese 网络主干搭建 (1D-CNN + GMP)

- **前提条件**：1D-CNN 的第一层卷积核感受野 K 必须满足 $K \geq M$，以从物理层面上吸收时分复用带来的时间错位噪声。
- **操作机制**：
  - **特征提取**：将 X_{v1} 和 X_{v2} 分别输入共享权重的多层 1D-CNN。
  - **物理降维**：接入全局最大池化层（GMP）。 算子 $y = \max_t(\mathrm{Conv1D}(X))$ 直接截取时间轴上的最恶劣失速尖峰，丢弃平均状态。
- **输出变量**：获得两个代表执行阻力的一维标量 y_{v1} 和 y_{v2}。

4. 概率空间映射与梯度驱动 (Loss Computation)

- **前提条件**：放弃标量间的绝对距离约束，仅要求网络学习单调递增的偏序关系。
- **操作机制**：
  - 计算标量差值，并通过 Sigmoid 函数映射为偏序概率 $p = \frac{1}{1+e^{-(y_{v1}-y_{v2})}}$。

- 结合第一步生成的标签 t，计算二元交叉熵损失：
  $L = -[t \cdot \log(p) + (1-t) \cdot \log(1-p)]$。
- 反向传播更新 1D-CNN 权重。

5. 局部对偶验证 (Validation Scope Stricture)

- **前提条件**：彻底切断跨流形的标量比较路径。
- **操作机制**：
  - 测试集必须由严格配对的同程序样本 $(ProgramA_{opt}, ProgramA_{unopt})$ 构成。
  - 仅验证网络输出的概率 p 是否大于 0.5 且与实际吞吐量优劣一致。
  - 明确拒绝诸如 $y(ProgramA_{opt})$ 与 $y(ProgramB_{unopt})$ 的数值大小比对。

6. 推理与验证阶段（Inference / Validation）的最终输出

输出变量： 一个单一的相对概率值 p（标量），取值范围严格映射在 $(0, 1)$ 区间内。

机制与判断逻辑： * **物理含义：** 该概率 p 仅代表“版本 $v1$ 的性能优于版本 $v2$”的置信度。 * 若 $p > 0.5$：模型判断 $v1$ 的实际吞吐量大于 $v2$（即 $v1$ 的执行效率更高、底层阻力更小）。 * 若 $p < 0.5$：模型判断 $v2$ 优于 $v1$。